

LAB 5 Multi-Layer Perceptron

1. โหลดชุดข้อมูล Iris จาก sklearn.datasets โดยใช้คำสั่ง

```
from sklearn.datasets import load_iris
data = load_iris()
```

2. แสดงรายการ features และรายการลาเบล (label) ตามลำดับ

รายการ features	
รายการลาเบล	0 = , 1 = , 2 =

3. จงเข้ารหัสลาเบลในชุดข้อมูลนี้โดยใช้ OnehotEncoder()

Label	Binary code
setosa	
versicolor	
virginica	

4. แบ่งชุดข้อมูลนี้ออกเป็น 75% สำหรับฝึกโมเดล (train) และ 25% สำหรับทดสอบ (test)

5. ใช้ชุดข้อมูลฝึกในข้อ 3 เพื่อฝึกโมเดล MLP โดยกำหนดไฮเปอร์พารามิเตอร์ ดังต่อไปนี้

ชั้น hidden layer	(50,)
Learning rate	0.005
Solver	'sgd'
Activation function	'logistic'
Maximum iteration	1,000

6. Plot กราฟแสดงค่า loss ในแต่ละรอบ

7. แสดงค่าความแม่นยำของโมเดลบนชุดข้อมูลทดสอบ

8. ใช้ชุดข้อมูลฝึกในข้อ 3 เพื่อค้นหาโมเดลพารามิเตอร์ที่เหมาะสม จากรายการต่อไปนี้ โดยใช้ GridSearchCV กำหนดให้ cv = 5

ชั้น hidden layer	(5,), (20,), (5, 5), (5, 20), (5, 20, 5)
Activation function	'logistic', 'relu'
solver	'sgd', 'adam'
Learning rate	0.0001, 0.001, 0.005

ผลลัพธ์ที่ได้จาก cv ได้แก่

LAB 5 Multi-Layer Perceptron

9. ค่าความแม่นยำโมเดลในข้อ 8 บนชุดข้อมูลทดสอบ,,,,,,
10. จำนวนพารามิเตอร์ระหว่างชั้นอินพุตและชั้นซ่อน เท่ากับ
11. จำนวนพารามิเตอร์ระหว่างชั้นซ่อนและชั้นเอาต์พุต เท่ากับ

12. โหลดชุดข้อมูล bike rental จาก google classroom

instant	date	season	temp	humi	windspeed	casual	registered
1	1/1/2011	1	34.417	8.058	1.604	331	654
2	2/1/2011	1	36.348	6.961	2.485	131	670
3	3/1/2011	1	19.636	4.373	2.483	120	1229
4	4/1/2011	1	20.000	5.904	1.603	108	1454
5	5/1/2011	1	22.696	4.370	1.869	82	1518
6	6/1/2011	1	20.435	5.183	0.896	88	1518
7	7/1/2011	1	19.652	4.987	1.687	148	1362
8	8/1/2011	1	16.500	5.358	2.668	68	891
9	9/1/2011	1	13.833	4.342	3.620	54	768
10	10/1/2011	1	15.083	4.829	2.233	41	1280
11	11/1/2011	1	16.909	6.864	1.221	43	1220
12	12/1/2011	1	17.273	5.995	3.046	25	1137

13. สร้าง features เพิ่มเติม สอดคล้องกับข้อมูล date ดังนี้

Feature name	Value (meaning)
weekday	0 ('Sunday') - 6 ('Saturday')
working_day	0 ('weekend'), 1 ('working day')
month	0 ('January') - 11 ('December')
lag_feature_1	casual(t-1) + registred(t-1)
lag_feature_2	casual(t-2) + registred(t-3)
lag_feature_3	casual(t-3) + registred(t-3)

14. สร้างคอลัมน์เอาต์พุต $cnt = casual(t+1) + registred(t+1)$ ซึ่งเป็นจำนวนจักรยานรวมที่ถูกเช่าในวันถัดไป

15. แบ่งข้อมูลจากข้อ 15 เป็นชุดข้อมูลฝึก (train dataset) 18 เดือนแรก และชุดข้อมูลทดสอบ 6 เดือนสุดท้าย

LAB 5 Multi-Layer Perceptron

16. สร้างโมเดล MLP Regressor เพื่อคาดการณ์จำนวนจักรยานรวม $t+1$ โดยเลือกจากรายการไฮเปอร์พารามิเตอร์จากรายการด้านล่าง และฝึกด้วยชุดข้อมูล train จำนวนรอบสูงสุด 2,000 รอบ กำหนดให้ $cv = 5$

ชั้น hidden layer	(50,), (10, 10), (10, 50), (10, 50, 5)
Activation function	'logistic', 'identity', 'relu'
solver	'sgd', 'adam'
Learning rate	0.0001, 0.001, 0.005
n_iter_no_change	10, 50

17. พล็อต loss curve ของการฝึกโมเดล
18. คำนวณ R^2 บนชุดข้อมูลทดสอบเทียบกับคำตอบ (ground truth)
19. เปรียบเทียบ R^2 ของโมเดล MLP เทียบกับ R^2 ของ Linear Regression สรุปได้ว่าโมเดล
ให้ความสอดคล้อง (correlation) กับผลเฉลยสูงกว่า